

LEMBAR KERJA-04 (LK-04)

Implementasi Pipeline Data Ingestion & Preprocessing Berbasis MLOps

**Sistem Otomatis Deteksi Anomali Data Cuaca Open-Meteo untuk Smart
Farming Berbasis MLOps**

MLOPS TIF-B 2026

Nama Mahasiswa:

Muhammad Ghazy Humaidi (245150200111071)

Dosen Pengampu:

Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.

Program Studi Teknik Informatika

Jurusan Teknik Informatika

Fakultas Ilmu Komputer, Universitas Brawijaya

2026

RINGKASAN DAN DAFTAR ISI

Informasi Akademik	Detail Implementasi Mahasiswa
Nama Mahasiswa / NIM	Muhammad Ghazy Humaidi / 245150200111071
Mata Kuliah / Dosen	MLOps — TIF-B 2026 / Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.
Institusi	Teknik Informatika, FILKOM, Universitas Brawijaya
Repositori GitHub & Branch	MLOps-AnomaliCuacaOpenMeteo (feat/lk04-data-ingestion-preprocessing)
Cakupan Tugas LK-04	Data Ingestion (Airflow), Quality Gate, Anomaly Labeling, & Feature Engineering
Status Verifikasi	67 / 67 Unit Tests Pass (100%), Output 720 baris x 40 kolom terverifikasi

Struktur laporan implementasi LK-04 tersusun atas 5 bab utama:

BAB 1: Implementasi dan Orkestrasi Data Ingestion (Apache Airflow & Open-Meteo)

- 1.1 Arsitektur Makro Infrastruktur Airflow & Lingkungan VM Server Lab
- 1.2 Logika Penjadwalan, Resolusi Path Dinamis, & Ketahanan Eksekusi DAG
- 1.3 Modul Inti Ingestion & Penanganan Jendela Geser Buffer 30 Hari (720 Baris)
- 1.4 Mekanisme Fault-Tolerant, Exponential Backoff, dan Fail-Fast Error Handling
- 1.5 Penulisan Berkas Atomik (_atomic_to_csv) dan Pencegahan Korupsi Data

BAB 2: Implementasi Pipeline Data Preprocessing & Quality Gate

- 2.1 Alur dan Dekomposisi Modular Tiga Fase ETL (DataCleaner, AnomalyLabeler, FeatureEngineer)
- 2.2 Phase 1 Quality Gate: Validasi Timestamp, Deduplikasi, dan Pembersihan Struktural
- 2.3 Phase 2 Rule-Based Anomaly Labeling (Ground Truth 3-Kelas: Normal, Hardware, Extreme)
- 2.4 Matriks Taksonomi Deteksi Anomali Lengkap Berbasis Fisika Sensor dan Ambang Ekstrem

BAB 3: Rekayasa Fitur Agrometeorologi & Temporal (Feature Engineering)

- 3.1 Siklus Temporal & Kalender (Diurnal Sine/Cosine, Is-Weekend, Annual Month Waves)
- 3.2 Selisih Waktu (Temporal Lag Differences 1-Jam dan 24-Jam)
- 3.3 Statistik Jendela Geser (Rolling Window 3h, 6h, 24h Mean, Std, Min, Max)
- 3.4 Parameter Biofisik Agrometeorologi (Vapor Pressure Deficit / VPD dan Titik Embun / Dew Point)
- 3.5 Skema Kamus Data Final 40 Kolom (weather_features_v1.0.csv) dan Pelacakan DVC

BAB 4: Verifikasi, Pengujian Unit, dan Bukti Eksekusi Pipeline

- 4.1 Rangkaian Pengujian Unit Komprehensif (67 Unit Tests Pass 100%)
- 4.2 Hasil Eksekusi Ingestion & Analisis Buffer 720 Baris
- 4.3 Hasil Eksekusi Preprocessing & Profil Distribusi Anomali Riil
- 4.4 Panduan Operasional & Reproducibility (CLI Execution & Environment Setup)

BAB 5: Kesimpulan dan Langkah Selanjutnya (Model Training LK-05)

- 5.1 Kesimpulan Capaian Rekayasa Pipeline Data
- 5.2 Roadmap Menuju Continuous Training & Model Serving


BAB 1: IMPLEMENTASI DAN ORKESTRASI DATA INGESTION

1.1 Arsitektur Makro Infrastruktur Airflow & VM Server Lab

Pada perancangan LK-03, sistem penarikan data cuaca dirancang untuk beroperasi secara mandiri dan berkala di atas infrastruktur server berbasis Linux. Untuk memenuhi kriteria operasional LK-04, sistem diimplementasikan pada lingkungan Ubuntu Server dengan spesifikasi perangkat keras terbatas (2 vCPU, 2 GB RAM, 20 GB Disk) yang mencerminkan karakteristik edge computing atau virtual private server (VPS) agrikultur berbiaya rendah.

Untuk mencegah insiden kehabisan memori (Out-of-Memory / OOM Killer) yang sering melanda Apache Airflow pada mesin 2 GB RAM, arsitektur data ingestion dibangun dengan prinsip-prinsip rekayasa ketat:

1. Penggunaan SequentialExecutor dengan SQLite Metastore: Alih-alih menggunakan CeleryExecutor dengan broker Redis/RabbitMQ yang memakan alokasi RAM lebih dari 1.2 GB, implementasi mengadopsi SequentialExecutor yang sangat ringan (< 150 MB footprint RAM) dan bersifat deterministik untuk beban kerja serial per jam.
2. Penyediaan Linux Swap File 2 GB: Dipasang sebagai jaring pengaman (safety net) OS kernel Linux untuk mengantisipasi lonjakan beban sesaat saat kompilasi pustaka C/C++ atau startup worker.
3. Manajemen Proses Daemon 24/7 Berbasis Linux Systemd: Scheduler dan Webserver Airflow didaftarkan sebagai systemd service (airflow-scheduler.service dan airflow-webserver.service) dengan konfigurasi Restart=always dan RestartSec=5s, menjamin pipeline otomatis menyala kembali jika server mengalami reboot darurat.



Gambar 1.1: Diagram Alur Logika Eksekusi dan Resolusi Dinamis Apache Airflow DAG (weather_ingestion_dag.py)

1.2 Logika Penjadwalan & Ketahanan Eksekusi DAG

Berkas dags/weather_ingestion_dag.py mengorkestrasi penarikan data berkala setiap jam tepat pada menit ke-00 (cron: '0 * * * *'). Skrip DAG ini dirancang dengan isolasi proses mandiri (Process Isolation) di mana penarikan data tidak dieksekusi di dalam Python interpreter thread Airflow, melainkan didelegasikan ke BashOperator yang memicu subprocess independen:

```
[Snippet Konfigurasi dags/weather_ingestion_dag.py]
# Konfigurasi Parameter Proteksi Airflow DAG pada VPS 2 GB RAM
default_args = {
    'owner': 'mlops_engineer',
    'retries': 2,
    # Maksimal 2x retry jika koneksi internet terputus
```

```

'retry_delay': timedelta(minutes=2), # Jeda 2 menit sebelum mencoba ulang
'execution_timeout': timedelta(minutes=5), # Anti-zombie task (bunuh jika > 5 menit)
}
dag = DAG(
    'weather_data_ingestion',
    schedule_interval='0 * * * *', # Setiap pergantian jam
    catchup=False, # Cegah Backfill Storm saat Airflow baru dinyalakan
    max_active_runs=1, # Mencegah tabrakan konkurensi pada file CSV
)


```

Kelebihan utama mekanisme subprocess via BashOperator adalah pembersihan alokasi memori (RAM Reclamation): seketika skrip `src/data_ingestion.py` menyelesaikan eksekusi (Exit Code 0), seluruh footprint RAM sebesar ~80 MB yang dikonsumsi pustaka pandas langsung dilepaskan kembali ke sistem operasi Ubuntu, mencegah akumulasi memory leak.

Selain itu, DAG dilengkapi fungsi resolusi path dinamis cerdas (`get_repo_root()` dan `get_python_interpreter()`) yang mampu mengenali struktur repositori saat dipanggil oleh daemon `systemd` di Linux maupun saat diuji secara lokal di Windows, sekaligus mempreservasi symlink virtual environment sehingga `sys.prefix` dan berkas `pyvenv.cfg` tetap terbaca secara tepat.

1.3 Modul Inti Ingestion & Penanganan Buffer 30 Hari

Modul inti penarikan data cuaca diimplementasikan pada berkas `src/data_ingestion.py`, serta disediakan entripoint wrapper `src/ingest_data.py` untuk kemudahan antarmuka CLI. Modul ini bertanggung jawab mengumpulkan data meteorologi per jam dari Open-Meteo API untuk koordinat Kota Malang (Latitude -7.95, Longitude 112.61).



Gambar 1.2: Diagram Alur Pemrosesan Modul Ingestion (`src/data_ingestion.py`)

Modul menerapkan kebijakan penarikan adaptif (Adaptive Fetch Mode) guna mengoptimalkan efisiensi bandwidth dan keutuhan riwayat pelatihan:

- Mode Inisialisasi Buffer Awal (Cold Start): Jika berkas `data/raw/weather_raw_current.csv` belum terbentuk atau memiliki baris kurang dari kapasitas buffer (720 baris), modul secara otomatis menetapkan `past_days=30` untuk mengunduh 720 jam data historis sekaligus sebagai modal awal pembentukan riwayat 1 bulan.
- Mode Pembaruan Rutin (Incremental Ingestion): Apabila berkas buffer telah terisi penuh (720 baris), penarikan jam-jaman hanya menggunakan parameter `past_days=1` dan `forecast_days=1` (mengambil 24 jam terakhir) guna meminimalkan latensi jaringan dan konsumsi kuota API.
- Pengelolaan Jendela Geser (Sliding Window): Data baru digabungkan dengan data lama (`pd.concat`), dilakukan deduplikasi berbasis kolom timestamp (`drop_duplicates keep='last'`), diurutkan kronologis, dan dipotong tepat 720 baris terakhir (`tail(720)`). Baris ke-721 dan seterusnya (data hari ke-31 yang telah usang) secara otomatis tereliminasi, menjaga ukuran file raw CSV tetap konstan pada ~35 KB.

1.4 Mekanisme Fault-Tolerant & Exponential Backoff

Konektivitas jaringan menuju API pihak ketiga rentan mengalami gangguan transien (DNS timeout, packet drop, atau limitasi rate 429). Untuk menjamin keandalan data pipeline, fungsi `fetch_weather_data()` mengimplementasikan algoritma retry toleran galat jaringan dengan pola eksponensial (Exponential Backoff):

[Pola Jeda Eksponensial]

```
# Logika Jeda Eksponensial pada fetch_weather_data()
delay = initial_delay * (backoff_factor ** attempt)
# Percobaan 1: Gagal -> Menunggu 2.0 detik
# Percobaan 2: Gagal -> Menunggu 4.0 detik
# Percobaan 3: Gagal -> Menunggu 8.0 detik
# Percobaan 4: Melempar ConnectionError jika tetap gagal
```

Implementasi ini juga memisahkan penanganan jenis kesalahan HTTP secara tegas:

- Galat Transien (HTTP 5xx Server Error, HTTP 429 Too Many Requests, ConnectionTimeout): Ditangani melalui siklus retry eksponensial karena kemungkinan besar server akan pulih pada detik berikutnya.
- Galat Klien (HTTP 4xx Client Error seperti 400 Bad Request atau 404 Not Found): Sistem menerapkan pola Fail-Fast dengan langsung melempar eksepsi `ValueError` tanpa membuang waktu mencoba ulang, karena parameter request yang salah tidak akan pernah menghasilkan respons sukses.

1.5 Penulisan Berkas Atomik (`_atomic_to_csv`)

Salah satu risiko fatal pada pipeline streaming/micro-batch yang menulis langsung ke berkas target adalah timbulnya korupsi berkas (Torn Writes atau File Truncation) apabila proses terhenti mendadak di tengah penulisan akibat crash sistem atau interupsi kernel.

Untuk menjamin data integrity 100%, modul `src/data_ingestion.py` dan `src/data_preprocessing.py` mengimplementasikan fungsi khusus `_atomic_to_csv()`. Fungsi ini bekerja dengan dua langkah atomik:


1. Menulis DataFrame ke berkas temporer di direktori yang sama dengan menyematkan PID proses dan timestamp milidetik: `weather_raw_current.csv.<PID>_<TIMESTAMP>.tmp`.

2. Memanggil instruksi kernel tingkat rendah `os.replace(tmp_file, target_path)`. Pada sistem berkas Linux (POSIX) maupun Windows (NTFS), operasi penggantian nama berkas ini bersifat atomik—artinya pembaca hilir (downstream consumer) hanya akan melihat berkas lama utuh atau berkas baru yang sudah selesai 100%, tanpa pernah melihat kondisi berkas setengah tertulis.

BAB 2: IMPLEMENTASI PIPELINE DATA PREPROCESSING & QUALITY GATE

2.1 Alur dan Dekomposisi Tiga Fase ETL

Modul data preprocessing diimplementasikan pada berkas `src/data_preprocessing.py` (disertai entripoint wrapper `src/preprocess.py`). Modul ini mengadopsi arsitektur Object-Oriented Programming (OOP) modular yang memisahkan tanggung jawab pemrosesan menjadi tiga kelas independen yang diorkestrasi oleh fasad `WeatherPreprocessor`:



Gambar 2.1: Alur Tiga Fase Modular Pipeline Preprocessing & Feature Engineering (LK-04)

Fase Pemrosesan	Kelas Pelaksana	Tanggung Jawab Teknis Utama
Phase 1: Quality Gate	DataCleaner	Validasi skema 7 kolom mentah, parsing ISO 8601, pembuangan NaT, penegakan tipe numerik, dan deduplikasi.
Phase 2: Anomaly Labeling	AnomalyLabeler	Pelabelan ground truth 3-kelas deterministik (Class 0: Normal, Class 1: Hardware Fault, Class 2: Extreme Weather).
Phase 3: Feature Engineering	FeatureEngineer	Ekstraksi 40 fitur siap latih: sin/cos jam & bulan, lag difference, rolling window 3h/6h/24h, serta VPD dan Dew Point.
Pipeline Orchestrator	WeatherPreprocessor	Menggabungkan ketiga fase, mengelola I/O berkas CSV, dan melakukan penulisan atomik ke data/processed/.

2.2 Phase 1 Quality Gate: Pembersihan Struktural Data

Sebelum data mentah dapat diproses lebih lanjut, kelas `DataCleaner` bertindak sebagai gerbang mutu pertama (First Quality Gate). Langkah-langkah pembersihan meliputi:

- Validasi Kontrak Data (Schema Enforcement): Memastikan ketujuh kolom mentah wajib (`timestamp`, `temperature_2m_C`, `humidity_percent`, `precipitation_mm`, `soil_moisture`, `radiation_wm2`, `wind_speed_kmh`) hadir dalam `DataFrame`. Jika ada kolom yang hilang, sistem melempar `ValueError` seketika.

- Penanganan Timestamp Rusak: Kolom timestamp dikonversi menggunakan `pd.to_datetime(errors='coerce')`. Setiap baris yang menghasilkan NaT (Not a Time) dicatat ke dalam log peringatan dan langsung dibuang dari memori.
- Penjaminan Urutan Temporal & Deduplikasi: Baris diurutkan secara kronologis berdasarkan waktu (`sort_values('timestamp')`). Duplikasi observasi pada stempel waktu yang sama dieliminasi dengan mempertahankan rekaman terakhir (`keep='last'`).
- Penegakan Tipe Data Numerik: Seluruh variabel metrik fisik dikonversi ke float64 menggunakan `pd.to_numeric(errors='coerce')`, dengan sengaja mempertahankan nilai NaN (tidak langsung diimputasi) agar kegagalan transmisi paket sensor dapat dideteksi secara akurat oleh AnomalyLabeler.

2.3 Phase 2 Rule-Based Anomaly Labeling (3 Kelas Ground Truth)

Data cuaca mentah dari API Open-Meteo merupakan deret angka tak berlabel (unlabeled time-series). Dalam siklus hidup MLOps, ketiadaan label target (ground truth) diselesaikan melalui modul AnomalyLabeler yang mengevaluasi setiap baris data terhadap taksonomi kegagalan sensor IoT dan batas toleransi tanaman yang dirumuskan pada LK-03 Bab 2 & 3:

Kode Kelas	Nama Label Kelas	Prioritas Evaluasi	Makna Operasional Smart Farming
0	Class 0: Normal State	Prioritas 3 (Default)	Kondisi cuaca wajar khas Malang. Sistem irigasi cerdas beroperasi mengikuti jadwal standar normal.
1	Class 1: Hardware Fault	Prioritas 1 (Tertinggi)	Kerusakan fisik sensor, korsleting listrik, register macet, atau putus transmisi. Aktuator dilarang merespons data palsu.
2	Class 2: Extreme Environmental	Prioritas 2 (Menengah)	Fenomena iklim ekstrem riil (gelombang panas, embun upas, badai, kekeringan kritis). Memicu tindakan darurat aktuator.

2.4 Matriks Taksonomi Deteksi Anomali Lengkap

Tabel di bawah ini mendokumentasikan secara rinci kriteria matematis, kondisi fisik, dan string alasan deteksi (`anomaly_reason`) yang dihasilkan oleh modul AnomalyLabeler:

Kategori Anomali	Kondisi Logika Matematis	Alasan Anomali (<code>anomaly_reason</code>) & Fenomena
Class 1: Missing Data	Kolom sensor bernilai NaN / Null	Hardware Fault: Missing / NaN in '<col>' (Packet loss sensor/brownout baterai).
Class 1: Out-of-Bounds	$T < -20^{\circ}\text{C}$ atau $T > 55^{\circ}\text{C}$	Hardware Fault: Temperature OOB (Korsleting termistor ADC saturasi).
Class 1: Out-of-Bounds	$\text{RH} < 0\%$ atau $\text{RH} > 100\%$	Hardware Fault: Humidity OOB (Resistansi kapasitif polimer rusak).
Class 1: Negative Values	$\text{Precip} < 0$ atau $\text{Rad} < 0$ atau $\text{Wind} < 0$	Hardware Fault: Negative <metrik> (Korupsi bit register / Op-Amp floating).
Class 1: Soil OOB	$\text{Soil} < 0.00$ atau $\text{Soil} > 0.55 \text{ m}^3/\text{m}^3$	Hardware Fault: Soil moisture OOB (Elektroda sensor tanah korosi/rusak).

Class 1: Night Glitch	Rad > 0.0 W/m ² pada jam 20:00 - 04:00 WIB	Hardware Fault: Night radiation glitch (Kebocoran fotodioda / lampu buatan).
Class 1: Discordance	Precip > 15 mm dan Rad > 800 W/m ²	Hardware Fault: Discordance (Hujan lebat di bawah terik matahari ekstrem).
Class 1: Discordance	$\Delta\text{Soil} > 0.30 \text{ m}^3/\text{m}^3$ saat Rad > 800 W/m ² & Rain = 0	Hardware Fault: Soil moisture surge (Genangan lokal tak wajar tanpa hujan).
Class 1: Discordance	Precip > 20 mm dan $ \Delta\text{Soil} < 0.0001 \text{ m}^3/\text{m}^3$	Hardware Fault: Soil probe unresponsive (Probe lepas kontak / air pocket gap).
Class 1: Spiking	$ \Delta T > 8.0^\circ\text{C}/\text{jam}$ tanpa presipitasi	Hardware Fault: Temperature spike (Fluktuasi voltase kabel / interferensi EMI).
Class 1: Stuck Value	$\sigma_T (12 \text{ jam}) = 0.0^\circ\text{C}$	Hardware Fault: Temperature sensor stuck (Register mikrokontroler hang/macet).
Class 1: Stuck Value	RH $\geq$ 100% konstan selama > 24 jam	Hardware Fault: Humidity saturated 100% stuck (Sensor tertutup lumpur).
Class 1: Stuck Value	Wind $\leq$ 0.0 km/h konstan selama > 48 jam	Hardware Fault: Anemometer stuck at 0.0 km/h (Baling-baling mekanik macet).
Class 2: Heatwave	T > 33.5°C	Extreme Weather: Heatwave / Heat Stress (Stomata menutup, transpirasi akut).
Class 2: Severe Cold	T < 15.0°C	Extreme Weather: Severe Cold / Frost Risk (Risiko fenomena embun upas).
Class 2: Dry Air	RH < 40.0%	Extreme Weather: Severe Dry Air (Defisit uap air melonjak drastis).
Class 2: Torrential Rain	Precip > 25.0 mm/jam	Extreme Weather: Torrential Rainfall (Bahaya erosi tanah & genangan air).
Class 2: Critical Drought	Soil < 0.08 m ³ /m ³	Extreme Weather: Critical Drought / Wilting Point (Titik layu permanen akar).
Class 2: Waterlogging	Soil > 0.48 m ³ /m ³	Extreme Weather: Waterlogging / Root Anoxia (Akar tanaman kehabisan oksigen).
Class 2: Extreme Solar	Rad > 1100.0 W/m ²	Extreme Weather: Extreme Solar Radiation (Bahaya sunscald & klorosis daun).
Class 2: High Gale Wind	Wind > 40.0 km/h	Extreme Weather: High Gale Wind (Pohon rebah & kerusakan fisik greenhouse).

BAB 3: REKAYASA FITUR AGROMETEOROLOGI & TEMPORAL

3.1 Siklus Temporal & Kalender (Diurnal Sine/Cosine Waves)

Data cuaca memiliki periodisitas sirkadian (siklus 24 jam) dan musiman (siklus tahunan) yang kuat. Jika waktu hanya direpresentasikan sebagai bilangan bulat biasa (misal jam 0 hingga 23), model Machine Learning akan memperlakukan jarak antara jam 23:00 dan jam 00:00 bernilai selisih 23 satuan, padahal kenyataannya kedua jam tersebut hanya berjarak 1 jam.

Untuk mempertahankan kontinuitas topologis lingkaran waktu, kelas FeatureEngineer mengonversi komponen waktu kalender ke dalam transformasi trigonometri sinus dan kosinus:

[Rumus Fitur Siklis Temporal]

```
# Transformasi Trigonometri Siklis Waktu
hour_sin = sin(2 * pi * hour / 24.0)
hour_cos = cos(2 * pi * hour / 24.0)
month_sin = sin(2 * pi * (month - 1) / 12.0)
month_cos = cos(2 * pi * (month - 1) / 12.0)
is_weekend = 1 if day_of_week in [5, 6] else 0
```

3.2 Selisih Waktu (Temporal Lag Differences)

Deteksi perubahan mendadak pada kondisi iklim membutuhkan fitur turunan waktu orde pertama. Modul FeatureEngineer mengekstraksi parameter laju perubahan (gradient):

- temp_diff_1h & temp_diff_24h: Menangkap lonjakan suhu antar jam dan fluktuasi suhu dibanding hari sebelumnya pada jam yang sama.
- humidity_diff_1h: Mengukur laju pengeringan udara atau kejenuhan pasca hujan.
- soil_diff_1h & soil_diff_24h: Mengukur dinamika infiltrasi air ke lapisan perakaran atau laju deplesi air tanah akibat evapotranspirasi.
- radiation_diff_1h: Mengidentifikasi perubahan tutupan awan secara mendadak.

3.3 Statistik Jendela Geser (Rolling Window Statistics)

Kondisi tanaman agrikultur tidak hanya dipengaruhi oleh cuaca sesaat, melainkan akumulasi stres termal dan ketersediaan air dalam rentang waktu beberapa jam hingga 24 jam terakhir. Oleh karena itu, modul menghitung agregasi statistik:

- Suhu: Rata-rata dan standar deviasi pada jendela 3 jam, 6 jam, dan 24 jam (temp_rolling_mean_3h, temp_rolling_std_3h, temp_rolling_mean_24h, temp_rolling_std_24h), serta suhu minimum dan maksimum 24 jam terakhir.
- Kelembaban: Rata-rata bergerak 6 jam dan 24 jam (humidity_rolling_mean_6h, humidity_rolling_mean_24h).
- Akumulasi Presipitasi: Jumlah curah hujan 6 jam dan 24 jam terakhir (precip_rolling_sum_6h, precip_rolling_sum_24h) untuk mengidentifikasi tingkat kejenuhan air tanah.
- Angin: Kecepatan rata-rata 6 jam dan hembusan maksimum 24 jam (wind_rolling_mean_6h, wind_rolling_max_24h).

3.4 Parameter Biofisik Agrometeorologi (VPD & Dew Point)

Dua metrik biofisik fundamental ditambahkan ke dalam dataset olahan untuk mendukung domain Smart Farming:

1. Vapor Pressure Deficit (VPD dalam kPa): Mengukur selisih antara tekanan uap jenuh (saat udara 100% basah) dan tekanan uap air aktual di udara. VPD merupakan indikator terbaik untuk laju transpirasi tanaman dan potensi stres kekeringan kanopi daun:

```
[Formula Fisika Vapor Pressure Deficit]
# Perhitungan Vapor Pressure Deficit (VPD)
e_s (Tekanan Uap Jenuh, kPa) = 0.61078 * exp((17.27 * T) / (T + 237.3))
e_a (Tekanan Uap Aktual, kPa) = e_s * (RH / 100.0)
VPD (kPa) = max(0.0, e_s - e_a)
```

2. Titik Embun / Dew Point (°C): Menggunakan aproksimasi formula empiris Magnus-Tetens untuk menentukan suhu di mana udara mencapai titik jenuh uap air dan mulai membentuk embun:


```
[Formula Titik Embun (Dew Point)]
# Formula Magnus-Tetens untuk Titik Embun
alpha = ((17.27 * T) / (237.3 + T)) + ln(max(RH, 0.01) / 100.0)
T_dew (°C) = (237.3 * alpha) / (17.27 - alpha)
```

3.5 Skema Data Final 40 Kolom & Kamus Data

Hasil akhir dari proses data preprocessing adalah berkas tabular berstandar MLOps data/processed/weather_features_v1.0.csv yang memiliki tepat 40 kolom fitur. Tabel berikut merangkum kamus data fitur olahan:

Kategori Fitur	Nama Atribut Kolom	Tipe Data	Satuan Ukur	Deskripsi Fungsional
Identitas & Raw	timestamp	datetime64	YYYY-MM-DD HH:MM	Waktu observasi cuaca per jam lokal WIB.
Identitas & Raw	temperature_2m_C	float64	°C	Suhu udara aktual 2 meter di atas permukaan.
Identitas & Raw	humidity_percent	float64	%	Kelembaban relatif udara aktual.
Identitas & Raw	precipitation_mm	float64	mm/jam	Curah hujan aktual dalam interval 1 jam.
Identitas & Raw	soil_moisture	float64	m ³ /m ³	Kandungan air tanah lapisan atas (0-7 cm).
Identitas & Raw	radiation_wm2	float64	W/m ²	Radiasi gelombang pendek sinar matahari.
Identitas & Raw	wind_speed_kmh	float64	km/h	Kecepatan angin elevasi 10 meter.
Target Ground Truth	anomaly_class	int64	0, 1, 2	Label kelas: 0 (Normal), 1 (Hardware), 2 (Ekstrem).

Target Ground Truth	anomaly_reason	object	Teks	String rincian penyebab penandaan anomali.
Siklus Temporal	hour, day_of_week, month	int64	Integer	Komponen kalender berbasis waktu pencatatan.
Siklus Temporal	hour_sin, hour_cos	float64	[-1, 1]	Transformasi trigonometri siklus diurnal 24 jam.
Siklus Temporal	month_sin, month_cos	float64	[-1, 1]	Transformasi trigonometri siklus musiman 12 bulan.
Siklus Temporal	is_weekend	int64	0 atau 1	Flag biner pembeda hari kerja vs akhir pekan.
Biofisik Agrikultur	vpd_kpa	float64	kPa	Vapor Pressure Deficit (defisit tekanan uap).
Biofisik Agrikultur	dew_point_C	float64	°C	Titik embun udara (kondensasi uap air).
Selisih Lag	temp_diff_1h, temp_diff_24h	float64	°C	Laju perubahan suhu dalam 1 jam dan 24 jam.
Selisih Lag	humidity_diff_1h, radiation_diff_1h	float64	% / W/m ²	Perubahan kelembaban dan fluks radiasi 1 jam.
Selisih Lag	soil_diff_1h, soil_diff_24h	float64	m ³ /m ³	Dinamika infiltrasi dan deplesi kelembaban tanah.
Statistik Rolling	temp_rolling_mean_3h, 6h, 24h	float64	°C	Rata-rata bergerak suhu multi-skala waktu.
Statistik Rolling	temp_rolling_std_3h, 6h, 24h	float64	°C	Volatilitas dan dispersi suhu udara.
Statistik Rolling	temp_rolling_min_24h, max_24h	float64	°C	Batas suhu ekstrem dalam siklus 24 jam.
Statistik Rolling	humidity_rolling_mean_6h, 24h	float64	%	Tren kelembaban udara jangka menengah.
Statistik Rolling	precip_rolling_sum_6h, 24h	float64	mm	Akumulasi curah hujan untuk deteksi banjir.
Statistik Rolling	soil_rolling_mean_24h	float64	m ³ /m ³	Ketersediaan air tanah rata-rata harian.
Statistik Rolling	wind_rolling_mean_6h, max_24h	float64	km/h	Kecepatan angin persisten dan hembusan puncak.



Gambar 3.1: Visualisasi Dinamika Fitur Cuaca, Nilai VPD, dan Hasil Pelabelan Anomali Riil (Buffer 30 Hari)

BAB 4: VERIFIKASI, PENGUJIAN UNIT, DAN BUKTI EKSEKUSI PIPELINE

4.1 Rangkaian Pengujian Unit Komprehensif (67 Unit Tests)

Untuk menjamin tidak adanya regresi logika dan membuktikan kehandalan seluruh komponen sistem secara objektif, repositori dilengkapi 67 unit test otomatis yang terbagi ke dalam tiga modul pengujian utama:

Modul Pengujian (Test Suite)	Jumlah Uji	Status	Aspek Sistem yang Divalidasi
tests/test_dags.py	26 Tests	PASS (100%)	Struktur DAG Airflow, resolusi interpreter Python di Windows & Linux, konfigurasi BashOperator, toleransi kegagalan pendulum, dan penanganan dependensi.
tests/test_data_ingestion.py	15 Tests	PASS (100%)	Pengambilan payload API, mekanisme retry backoff, parsing skema mentah, deduplikasi timestamp, pemotongan buffer 720 baris, dan penulisan atomik.
tests/test_data_preprocessing.py	26 Tests	PASS (100%)	DataCleaner (Quality Gate), AnomalyLabeler (taksonomi kegagalan sensor Class 1 & 8 kondisi cuaca ekstrem Class 2, presisi float stuck value, spiking negatif, timezone), FeatureEngineer, dan integrasi I/O berkas.
TOTAL RANGKAIAN UJI	67 Tests	PASS (100%)	Seluruh pengujian unit berjalan sukses dalam waktu 1.35 detik tanpa kegagalan.

Berikut adalah rekaman log resmi eksekusi seluruh unit test menggunakan test runner unittest:

```
[Log Eksekusi Unit Tests Repositori]
$ python -m unittest discover tests
..... [26 tests test_dags.py]
..... [15 tests test_data_ingestion.py]
..... [26 tests test_data_preprocessing.py]
-----
Ran 67 tests in 1.352s

OK
```

4.2 Hasil Eksekusi Ingestion & Analisis Buffer 720 Baris

Modul data ingestion berhasil dijalankan dan menghasilkan berkas raw buffer data/raw/weather_raw_current.csv dengan ringkasan karakteristik sebagai berikut:

- Total Observasi: 720 baris terurut kronologis tanpa ada jeda jam (100% time-series continuity).
- Rentang Waktu: 2026-08-29 00:00:00 WIB s.d. 2026-09-27 23:00:00 WIB (tepat 30 hari observasi).

- Ukuran Berkas di Disk: 34.671 byte (~34.7 KB), sangat hemat dan ideal untuk sinkronisasi DVC.
- Konsistensi Skema: 7 kolom mentah terisi utuh tanpa perubahan nama atribut.

4.3 Hasil Eksekusi Preprocessing & Profil Distribusi Anomali

Pipeline pemrosesan data dieksekusi menggunakan modul `src/data_preprocessing.py` pada berkas raw buffer 720 baris tersebut. Hasil eksekusi menghasilkan dataset fitur berlabel `data/processed/weather_features_v1.0.csv` (dan salinan `data/processed/weather_processed_current.csv`):

```
[Log Eksekusi Pipeline Data Preprocessing]
$ python src/data_preprocessing.py
[START] Memulai Pipeline Data Preprocessing (MLOps LK-04)
  Input Path   : data/raw/weather_raw_current.csv
  Output Path  : data/processed/weather_features_v1.0.csv
  Current Path : data/processed/weather_processed_current.csv

[SUCCESS] Preprocessing Berhasil Selesai!
Total baris diproses: 720
Total kolom fitur   : 40

[SUMMARY] Ringkasan Distribusi Anomali (Ground Truth):
- Class 0: Normal State      : 666 baris (92.50%)
- Class 1: Hardware Fault    : 0 baris (0.00%)
- Class 2: Extreme Weather   : 54 baris (7.50%)
```

Analisis mendalam terhadap profil anomali yang terdeteksi menunjukkan temuan yang sangat selaras dengan klimatologi riil:

1. Class 0: Normal State mendominasi 92.50% (666 baris) data, merefleksikan kondisi cuaca harian kota Malang yang sebagian besar berada dalam batas toleransi normal.
2. Class 1: Hardware Fault bernilai 0 baris (0.00%). Hal ini merupakan perilaku yang diharapkan secara ilmiah karena sumber data berasal dari reanalisis model numerik Open-Meteo yang telah melalui filtering internal, sehingga tidak mengandung derau elektrik buatan. Kemampuan deteksi Class 1 telah diverifikasi lulus 100% melalui skenario injeksi sintesis pada unit test.
3. Class 2: Extreme Environmental Anomaly terdeteksi sebanyak 54 baris (7.50%). Seluruh 54 baris anomali tersebut dipicu oleh kondisi Severe Dry Air (kelembaban udara $31\% - 38\% < 40\%$) yang terjadi secara berulang pada siang hari terik (pukul 11:00 - 14:00 WIB) di akhir bulan Agustus dan awal September 2026. Pada konteks Smart Farming, anomali ini mencerminkan fenomena defisit tekanan uap (VPD spike > 2.8 kPa) yang nyata di mana tanaman rentan mengalami layu mendadak akibat transpirasi akut, membuktikan bahwa aturan taksonomi LK-03 berhasil mengidentifikasi kondisi kritis lapangan secara tepat sasaran.

4.4 Panduan Operasional & Reproducibility (CLI Execution)

Untuk memfasilitasi auditabilitas dan pengujian independen oleh dosen penguji atau rekan peneliti, seluruh pipeline dapat direproduksi melalui baris perintah (CLI) terstandar:

```
[Perintah Operasional Pipeline]
# 1. Eksekusi Data Ingestion (Tarik data & perbarui buffer)
```

```
python src/data_ingestion.py --past-days 30 --buffer-size 720
# Atau via entrypoint wrapper:
python src/ingest_data.py

# 2. Eksekusi Data Preprocessing & Feature Engineering
python src/data_preprocessing.py --input-path data/raw/weather_raw_current.csv \
                                --output-path data/processed/weather_features_v1.0.csv
# Atau via entrypoint wrapper:
python src/preprocess.py

# 3. Menjalankan Seluruh Rangkaian Unit Test (67 Uji)
python -m unittest discover tests
```

BAB 5: KESIMPULAN DAN LANGKAH SELANJUTNYA

5.1 Kesimpulan Capaian Rekayasa Pipeline Data

Implementasi Lembar Kerja 04 (LK-04) telah berhasil menuntaskan seluruh sasaran rekayasa data tingkat operasional:

1. Ingestion Otomatis & Andal: Apache Airflow DAG berhasil menjadwalkan penarikan data jam-jaman dari Open-Meteo API dengan isolasi memori subprocess, mekanisme toleransi galat exponential backoff, penulisan berkas atomik, dan pemeliharaan rolling buffer 30 hari (720 baris).
2. Quality Gate & Ground Truth Deterministic: Modul DataCleaner dan AnomalyLabeler sukses menegakkan integritas skema data serta mengklasifikasikan data ke dalam 3 kelas anomali (Normal, Hardware Fault, Extreme Weather) sesuai taksonomi fisik LK-03.
3. Feature Engineering Kaya Fitur: Berhasil mengekstraksi 40 atribut fitur berstandar machine learning, mencakup transformasi sinus/kosinus waktu, selisih lag, statistik jendela geser multi-skala, dan variabel biofisik agrikultur (VPD & Dew Point).
4. Kualitas Kode Tinggi & Teruji: Seluruh 67 unit test lulus 100% tanpa galat, membuktikan ketahanan sistem terhadap kasus ekstrem (edge cases) seperti data kosong, missing values, dan malformasi timestamp.

5.2 Roadmap Menuju Model Training & Serving (LK-05)

Dengan tersedianya dataset olahan data/processed/weather_features_v1.0.csv yang memiliki 40 fitur lengkap dan label ground truth objektif, pondasi data untuk tahap berikutnya telah matang 100%. Pada Lembar Kerja 05 (LK-05), tahapan yang akan direalisasikan meliputi:

- Pelatihan Model Multiclass: Melatih algoritma klasifikasi (Random Forest dan XGBoost Classifier) menggunakan teknik penyeimbangan kelas (SMOTE / Class Weighting) untuk menangani ketimpangan distribusi (class imbalance).
- Pelacakan Eksperimen via MLflow: Mencatat metrik performa (Macro F1-Score > 85%, Confusion Matrix, PR-AUC) serta mendaftarkan model Champion ke MLflow Model Registry.
- Model Serving Real-Time via FastAPI: Mengemas model terlatih ke dalam endpoint REST API berlatensi rendah (< 100 ms) di dalam wadah Docker.
- Integrasi Closed-Loop Monitoring: Menghubungkan Evidently AI untuk mendeteksi Data Drift dan Concept Drift pada data cuaca harian guna memicu retraining otomatis.