

LEMBAR KERJA-05 (LK-05)

Manajemen Data Versioning Menggunakan DVC

Sistem Otomatis Deteksi Anomali Data Cuaca Open-Meteo untuk Smart Farming Berbasis MLOps

MLOPS TIF-B 2026

Nama Mahasiswa:

Muhammad Ghazy Humaidi (245150200111071)

Dosen Pengampu:

Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.

Program Studi Teknik Informatika

Jurusan Teknik Informatika

Fakultas Ilmu Komputer, Universitas Brawijaya

2026

RINGKASAN DAN DAFTAR ISI

Informasi Akademik	Detail Implementasi Mahasiswa
Nama Mahasiswa / NIM	Muhammad Ghazy Humaidi / 245150200111071
Mata Kuliah / Dosen	MLOps — TIF-B 2026 / Rizal Setya Perdana, S.Kom., M.Kom., Ph.D.
Institusi	Teknik Informatika, FILKOM, Universitas Brawijaya
Repositori GitHub & Branch	MLOps-AnomaliCuacaOpenMeteo (feat/lk05-dvc-versioning)
Cakupan Tugas LK-05	Inisialisasi DVC, pelacakan dataset, simulasi data baru, audit diff antar versi
Hasil Utama	2 versi dataset terlacak: dataset-v1.0.0 (720 baris) → dataset-v2.0.0 (936 baris)

DAFTAR ISI

BAB 1: PENDAHULUAN DAN KONSEP DATA VERSIONING	3
1.1 Latar Belakang dan Tujuan	3
1.2 Konsep Dasar DVC pada Proyek Ini	3
BAB 2: SETUP DVC DAN REMOTE STORAGE	3
2.1 Instalasi dan Inisialisasi	3
2.2 Konfigurasi Remote Storage di Luar Repositori	4
BAB 3: PELACAKAN DATASET DAN SIMULASI CONTINUAL LEARNING	4
3.1 Versi 1: Pelacakan Dataset Awal (Baseline LK-04)	4
3.2 Simulasi Continual Learning: Pengambilan Data Tambahan	4
3.3 Versi 2: Pelacakan Dataset yang Diperbarui	5
BAB 4: AUDIT DAN PERBANDINGAN VERSI DATASET	5
4.1 Status dan Diff Metadata dengan DVC	5
4.2 Perubahan File Penunjuk pada Git	6
4.3 Analisis Isi Perbedaan Data	6
4.4 Pemulihan Versi Tertentu (Checkout)	6
BAB 5: PENTINGNYA DATA VERSIONING UNTUK REPRODUKSIBILITAS MODEL	7
5.1 Mengapa Versioning Dataset Krusial	7
5.2 Alur Reproduksi dan Kapan Versi Dibuat	7
5.3 Alur Penambahan Versi Data dan Keterbatasan	8
BAB 6: KESIMPULAN	8

BAB 1: PENDAHULUAN DAN KONSEP DATA VERSIONING

1.1 Latar Belakang dan Tujuan

Pada LK-04, pipeline ingestion Apache Airflow menarik data cuaca Open-Meteo setiap jam dan menyimpannya pada rolling buffer 30 hari (720 baris) di `data/raw/weather_raw_current.csv`. Karena buffer bersifat bergulir, isi berkas yang sama berubah setiap jam: data tertua keluar, data terbaru masuk. Git pada dasarnya tidak dirancang untuk menyimpan berkas data yang berubah terus-menerus dan berukuran besar atau biner, sehingga riwayat repositori akan membengkak dan isi data tertentu tidak dapat dipanggil kembali secara bermakna.

LK-05 bertujuan mengintegrasikan DVC (Data Version Control) ke dalam repositori agar: (1) dataset awal hasil LK-04 dapat dilacak versinya tanpa membebani Git, (2) penambahan data baru (simulasi continual learning) tercatat sebagai versi baru dengan silsilah yang jelas, dan (3) dua versi dataset dapat dibandingkan secara objektif.

1.2 Konsep Dasar DVC pada Proyek Ini

DVC memisahkan satu versi data menjadi dua bagian yang disimpan di tempat berbeda. Pemisahan inilah yang menjaga repositori Git tetap ringan:

Komponen	Lokasi Penyimpanan	Fungsi
File penunjuk (.dvc)	Git (GitHub)	Teks kecil berisi hash MD5, ukuran, dan path berkas. Menjadi identitas satu versi data.
Cache DVC (.dvc/cache)	Lokal (di-ignore Git)	Salinan isi data per hash. Memungkinkan berpindah versi tanpa unduhan ulang.
Remote storage	Folder <code>~/dvc-store</code> pada VPS (SSH)	Penyimpanan eksternal di luar repositori untuk berbagi dan mencadangkan isi data.
Tag Git (dataset-vX.Y.Z)	Git (GitHub)	Label yang mudah dibaca untuk menunjuk commit dengan versi data tertentu.

BAB 2: SETUP DVC DAN REMOTE STORAGE

2.1 Instalasi dan Inisialisasi

DVC dipasang dengan ekstensi SSH karena remote storage menggunakan protokol SSH, dan versinya dikunci pada `requirements.txt` agar lingkungan dapat direproduksi. Pekerjaan dilakukan pada branch terpisah sesuai GitHub Flow (`feat/lk05-dvc-versioning`).

[Inisialisasi DVC]

```
$ git checkout -b feat/lk05-dvc-versioning
$ pip install "dvc[ssh]==3.67.1"          # dicatat pada requirements.txt
$ dvc init
$ git commit -m "chore(dvc): initialize DVC"
```

Perintah `dvc init` membentuk direktori `.dvc/` (konfigurasi dan cache), berkas `.dvc/.gitignore`, serta `.dvcignore`. Berkas-berkas konfigurasi ini yang di-commit ke Git, sedangkan cache lokal tidak.

2.2 Konfigurasi Remote Storage di Luar Repositori

Sebagai penyimpanan eksternal (butir opsional tugas), digunakan folder ~/dvc-store pada VPS Ubuntu yang sama dengan server Airflow, diakses melalui SSH. Pendekatan ini tidak memerlukan instalasi DVC pada VPS karena VPS hanya berperan sebagai gudang berkas.

[Konfigurasi remote DVC]

```
$ ssh member@10.34.211.189 "mkdir -p ~/dvc-store"
$ dvc remote add -d vps ssh://member@10.34.211.189/home/member/dvc-store
$ dvc remote list
vps      ssh://member@10.34.211.189/home/member/dvc-store      (default)
$ git add .dvc/config && git commit -m "chore(dvc): add SSH remote on VPS"
```

Catatan operasional: VPS hanya dapat diakses dari jaringan UB, sehingga dvc push dan dvc pull hanya berfungsi saat terhubung ke jaringan tersebut. Untuk penggunaan lintas jaringan, remote dapat dialihkan ke S3, GCS, atau MinIO tanpa mengubah alur kerja yang dijelaskan pada laporan ini.

BAB 3: PELACAKAN DATASET DAN SIMULASI CONTINUAL LEARNING

3.1 Versi 1: Pelacakan Dataset Awal (Baseline LK-04)

Dataset awal adalah buffer mentah hasil LK-04 berisi 720 baris (2026-08-29 s.d. 2026-09-27, 34.671 byte). Berkas ini dilacak dengan dvc add, yang menghitung hash MD5 isi berkas dan menulis file penunjuk yang kemudian di-commit serta diberi tag.

[Versi 1: dvc add dan file penunjuk]

```
$ dvc add data/raw/weather_raw_current.csv
$ git add data/raw/weather_raw_current.csv.dvc
$ git commit -m "data: track raw weather dataset v1 (720 rows, 2026-08-29 to 2026-09-27)"
$ git tag dataset-v1.0.0

# isi data/raw/weather_raw_current.csv.dvc (v1)
outs:
- md5: e42dc025e5df6d31f780db84ee5836d3
  size: 34671
  hash: md5
  path: weather_raw_current.csv
```

Berkas CSV itu sendiri tidak masuk ke Git: pola data/raw/*.csv sudah terdaftar pada .gitignore proyek, sehingga yang tercatat di Git hanya file penunjuk .dvc berukuran puluhan byte.

3.2 Simulasi Continual Learning: Pengambilan Data Tambahan

Skrip ingestion dijalankan kembali untuk mengambil data terbaru dari Open-Meteo. Ukuran buffer default dikunci 720 baris sehingga data baru hanya menggeser jendela (baris lama keluar) dan jumlah baris tidak bertambah. Agar penambahan baris dapat didemonstrasikan sesuai tugas, buffer diperbesar menjadi 1000 baris melalui parameter --buffer-size. Skrip menggabungkan berkas lokal dengan hasil fetch 30 hari terakhir, melakukan deduplikasi timestamp (keep='last'), dan menyimpan secara atomik.

[Simulasi data baru]

```
$ python src/ingest_data.py --buffer-size 1000
# hasil: 936 baris data (937 baris dengan header), 2026-08-29 s.d. 2026-10-06 23:00
```

Sumber data live tetap berasal dari pipeline Airflow per jam pada VPS (LK-04). Pengambilan berkala, toleransi galat jaringan (retry dengan exponential backoff, fail-fast pada HTTP 4xx), dan penulisan atomik pada skrip ingestion memastikan data dinamis dapat ditarik otomatis dan konsisten.

3.3 Versi 2: Pelacakan Dataset yang Diperbarui

[Versi 2: hash pada file penunjuk berubah]

```
$ dvc add data/raw/weather_raw_current.csv
$ git add data/raw/weather_raw_current.csv.dvc
$ git commit -m "data: update raw weather dataset v2 (new rows from ingestion)"
$ git tag dataset-v2.0.0

# isi data/raw/weather_raw_current.csv.dvc (v2)
outs:
- md5: 8e4412625620af93ac368a5692e1a399
  size: 45033
  hash: md5
  path: weather_raw_current.csv
```

Ringkasan perbandingan karakteristik kedua versi dataset:

Atribut	dataset-v1.0.0	dataset-v2.0.0
Jumlah baris data	720	936 (+216 baris)
Rentang waktu	2026-08-29 00:00 s.d. 2026-09-27 23:00	2026-08-29 00:00 s.d. 2026-10-06 23:00
Ukuran berkas	34.671 byte	45.033 byte
MD5	e42dc025e5df6d31f780db84ee5836d3	8e4412625620af93ac368a5692e1a399
Nilai kosong (NaN)	0	0
Rata-rata suhu / kelembaban	23,35 °C / 72,19 %	23,54 °C / 73,05 %

BAB 4: AUDIT DAN PERBANDINGAN VERSI DATASET

4.1 Status dan Diff Metadata dengan DVC

dvc status memverifikasi bahwa isi berkas di workspace sesuai dengan hash pada file penunjuk, sedangkan dvc diff membandingkan dua versi data berdasarkan tag Git. Hasilnya menunjukkan berkas yang sama berstatus Modified dengan hash berubah dari e42dc025 menjadi 8e441262.

[Audit versi dengan DVC]

```
$ dvc status
Data and pipelines are up to date.

$ dvc diff dataset-v1.0.0 dataset-v2.0.0
Modified:
  data\raw\weather_raw_current.csv
```

```
files summary: 1 modified

$ dvc diff --show-hash dataset-v1.0.0 dataset-v2.0.0
Modified:
  e42dc025..8e441262  data\raw\weather_raw_current.csv

files summary: 1 modified
```

4.2 Perubahan File Penunjuk pada Git

Silsilah data juga terekam pada riwayat Git. Perbandingan file penunjuk antar tag memperlihatkan hanya dua nilai yang berubah, yaitu hash dan ukuran, sementara data berukuran puluhan kilobyte tidak ikut tersimpan di Git.

```
[Diff file penunjuk .dvc antar versi]
$ git diff dataset-v1.0.0 dataset-v2.0.0 -- data/raw/weather_raw_current.csv.dvc
outs:
-- md5: e42dc025e5df6d31f780db84ee5836d3
- size: 34671
+- md5: 8e4412625620af93ac368a5692e1a399
+ size: 45033
  hash: md5
  path: weather_raw_current.csv
```

4.3 Analisis Isi Perbedaan Data

Perbandingan isi kedua versi (berdasarkan timestamp) memberikan temuan yang penting bagi reproduksibilitas:

1. Penambahan data: 216 baris baru (9 hari x 24 jam, 2026-09-28 s.d. 2026-10-06) sehingga total menjadi 936 baris.
2. Revisi data lama: dari 720 baris yang tumpang tindih, 17 baris (seluruhnya pada 2026-09-27 pukul 07:00 s.d. 23:00) memiliki nilai yang berbeda pada v2: suhu 17 baris, kelembaban 16, curah hujan 6, kelembaban tanah 16, radiasi 10, dan kecepatan angin 16. Jam-jam tersebut berada di ujung rentang v1 saat data diambil, kemungkinan besar nilai prakiraan yang kemudian direvisi oleh model Open-Meteo. Dengan demikian, berkas dengan nama yang sama dapat berisi nilai berbeda untuk jam yang sama.
3. Dampak pada label ground truth: pipeline preprocessing yang sama (tanpa perubahan kode) menghasilkan distribusi kelas berbeda pada kedua versi, seperti ditunjukkan tabel berikut.

Kelas Anomali	Hasil pada v1 (720 baris)	Hasil pada v2 (936 baris)
Class 0: Normal State	666 (92,50%)	867 (92,63%)
Class 1: Hardware Fault	0 (0,00%)	0 (0,00%)
Class 2: Extreme Environmental	54 (7,50%)	69 (7,37%)

4.4 Pemulihan Versi Tertentu (Checkout)

Karena setiap versi terikat pada tag Git dan hash DVC, dataset dapat dikembalikan ke kondisi persis saat versi tersebut dibuat. Pengujian berikut menunjukkan berkas

data/raw/weather_raw_current.csv berpindah antara 720 baris (v1) dan 936 baris (v2) hanya dengan berpindah tag dan menjalankan dvc checkout.

[Berpindah antar versi dataset]

```
$ git checkout dataset-v1.0.0 && dvc checkout
M      data/raw/weather_raw_current.csv
$ wc -l data/raw/weather_raw_current.csv
721 data/raw/weather_raw_current.csv      # 720 baris data + 1 header
$ tail -1 data/raw/weather_raw_current.csv
2026-09-27 23:00:00,21.4,92,0.0,0.151,0.0,1.4

$ git checkout feat/lk05-dvc-versioning && dvc checkout
M      data/raw/weather_raw_current.csv
$ wc -l data/raw/weather_raw_current.csv
937 data/raw/weather_raw_current.csv      # 936 baris data + 1 header
$ tail -1 data/raw/weather_raw_current.csv
2026-10-06 23:00:00,21.5,95,0.0,0.213,0.0,5.8

$ dvc status
Data and pipelines are up to date.
```

BAB 5: PENTINGNYA DATA VERSIONING UNTUK REPRODUKSIBILITAS MODEL

5.1 Mengapa Versioning Dataset Krusial

Hasil sebuah model ditentukan oleh tiga hal: kode, konfigurasi, dan data. Git telah menjamin dua yang pertama, tetapi tanpa versioning data, eksperimen tidak dapat direproduksi. Bukti nyata muncul pada laporan ini: dua versi dataset menghasilkan jumlah baris, nilai pada jam yang sama, dan distribusi label yang berbeda (Class 2 berubah dari 54 menjadi 69 baris) walaupun kode preprocessing identik. Model yang dilatih pada v1 dan v2 akan berbeda, dan tanpa tag data, tidak ada cara untuk membuktikan model mana dilatih dengan data apa.

Pada proyek ini masalahnya lebih tajam karena buffer 30 hari bergulir: data lama otomatis terhapus dari berkas sumber dan nilai prakiraan dapat direvisi. Tanpa snapshot, kondisi data pada saat training hari ini tidak akan pernah dapat dipulihkan minggu depan. DVC menjadikan setiap snapshot yang dipilih permanen, terverifikasi hash, dan dapat dipulihkan kapan saja.

5.2 Alur Reproduksi dan Kapan Versi Dibuat

Satu versi data = satu commit Git (kode + file penunjuk) = satu tag. Untuk mereproduksi eksperimen, cukup memulihkan tag tersebut:

[Reproduksi eksperimen]

```
git checkout dataset-v1.0.0      # kode + file penunjuk .dvc versi 1
dvc checkout                     # (atau dvc pull pada clone baru) isi data persis versi 1
python src/preprocess.py         # preprocessing menghasilkan fitur & label yang sama
```

Versi dataset tidak dibuat setiap jam. Pengambilan per jam adalah tugas Airflow dan hanya memperbarui data hidup. Versi dibuat secara sengaja pada momen yang membutuhkan reproduksibilitas: baseline awal, sebelum training model, dan saat retraining terjadwal atau dipicu drift. Pada tahap training berikutnya, tag data (misalnya dataset-v2.0.0) dicatat bersama metrik pada experiment tracking sehingga setiap model memiliki asal data yang jelas.

5.3 Alur Penambahan Versi Data dan Keterbatasan

Langkah	Perintah	Tujuan
1. Ambil data baru	<code>python src/ingest_data.py --buffer-size 1000</code>	Menambah baris pada dataset
2. Catat versi baru	<code>dvc add data/raw/weather_raw_current.csv</code>	Menghitung hash dan memperbarui file .dvc
3. Commit dan tag	<code>git add *.dvc; git commit; git tag dataset-vX.Y.Z</code>	Mengikat versi data ke riwayat Git
4. Kirim data	<code>dvc push --all-tags</code>	Mengirim isi data ke remote (dahulukan)
5. Kirim penunjuk	<code>git push origin <branch> --tags</code>	Membagikan file penunjuk via GitHub
6. Audit	<code>dvc status; dvc diff <tagA> <tagB></code>	Memastikan silsilah dan perbedaan versi

Keterbatasan: (1) remote pada VPS hanya dapat diakses dari jaringan UB; (2) pada LK-05 yang dilacak hanya data mentah (data/raw), sedangkan data/processed adalah turunan deterministik dari data mentah dan kode preprocessing sehingga dapat dibangun ulang; (3) pembuatan versi dilakukan manual pada momen penting, bukan otomatis per jam.

BAB 6: KESIMPULAN

Seluruh sasaran LK-05 telah terpenuhi:

1. DVC berhasil diinisialisasi dan konfigurasinya di-commit ke Git, lengkap dengan remote storage eksternal berbasis SSH.
2. Dataset awal hasil LK-04 (720 baris) dilacak sebagai dataset-v1.0.0, dan penambahan data melalui skrip ingestion menghasilkan dataset-v2.0.0 (936 baris) dengan hash yang berubah.
3. Audit melalui `dvc status`, `dvc diff`, dan `git diff` membuktikan transisi versi (Modified: e42dc025 menjadi 8e441262), dan checkout membuktikan kedua versi dapat dipulihkan secara persis.
4. Analisis isi menunjukkan perbedaan nyata antar versi (216 baris baru, 17 baris direvisi, distribusi label berubah), yang menegaskan bahwa versioning dataset adalah syarat reproduksibilitas model.

Luaran yang Diminta	Lokasi pada Repositori
File penunjuk .dvc dan .gitignore	<code>data/raw/weather_raw_current.csv.dvc; .dvc/.gitignore; .gitignore</code>
Laporan singkat (PDF) dengan <code>dvc status/diff</code>	<code>Documentation/LK05/LK05-Muhammad Ghazy Humaidi-245150200111071.pdf</code>
Dokumentasi README alur versi data	<code>README.md</code> , bagian "Data Versioning (DVC)"